

דף נוסחאות – למידת מכונה ובריית מידע

פונקציות מרחק:

$$d(X, Y) = \left(\sum_{i=1}^n |x_i - y_i|^r \right)^{\frac{1}{r}}, \text{ For all } r \geq 1$$

Manhattan distance (L1 Norm: $r = 1$): $d = \sum_{i=1}^n |x_i - y_i|$

Euclidean Distance (L2 Norm: $r = 2$): $d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$

Chebychev Distance (L_∞ Norm: $r \in \mathbb{R}$): $d(x, y) = \max_i \{|x_i - y_i|\}$

The Cosine similarity: $\cos(X, Y) = \frac{x \cdot y}{\|x\| \cdot \|y\|}$

- where $x \cdot y$ denotes the vector dot product $x \cdot y = \sum_{i=1}^n x_i \cdot y_i$
- $\|x\|$ and $\|y\|$ denote the Euclidean norms

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} \text{ and } \|y\| = \sqrt{y_1^2 + y_2^2 + \dots + y_n^2}$$

אישכול (Clustering)

פונקציית Sum of Squared Error

$$SSE = \sum_{i=1}^k \sum_{x \in C_i} (c_i - x)^2$$

מדדים לאישכול היררכי

Single link: $d(C_i, C_j) = \min\{d(x_i, x_j)\}$

Complete link: $d(C_i, C_j) = \max\{d(x_i, x_j)\}$

Average Link: $d(C_i, C_j) = \text{avg}\{d(x_i, x_j)\}$

למידה מונחית – Supervised learning

אלגוריתם KNN

1. Given a dataset D and a new observation x , choose a distance metric:

$L_1, L_2, L_\infty, \cos(\theta), \dots$

1. Find the distance between x and all $x_j \in D$
2. Find the top k nearest neighbors
3. Use **voting** and classify the new observation

$w_i = \frac{1}{d_i^2}$ אלגוריתם KNN משקלי תצפיות

אלגוריתם KNN משקלי מאפיינים

$$D(X, Y) = \sqrt{(X - Y) \cdot M \cdot (X - Y)^T}$$

$$M = \begin{bmatrix} w_1 & 0 & 0 & 0 \\ 0 & w_2 & 0 & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & w_n \end{bmatrix}$$

עצי החלטה

Muti-way split	Binary split

אנטרופיה – מדד חוסר ודאות

$$H(X) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 - \dots - p_m \log_2 p_m$$

אנטרופיה מותנית –

$$H(X|Y) = \sum_{k=1}^k P(Y = k) \cdot H(X|Y = k)$$

Information Gain

$$\alpha(A, D) = H(D) - H_A(D)$$

כאשר $H_A(D)$ היא האנטרופיה לאחר פיצול העץ.

דחיסת מימדים – PCA

מטריצת השונות המשותפת:

$$COV = \frac{1}{n} \sum_{i=1}^n (x_i - \mu) \cdot (x_i - \mu)^T$$

מציאת ערכים עצמיים:

$$|COV - \lambda I| = 0$$

אלגוריתם Gradient Descent


W_x^* - the new weight

W_x - the old weight

α - learning rate

Each step, calculate:

$$W_x^* = W_x - \alpha \cdot \frac{\partial \text{Error}}{\partial W_x}$$



פונקציית Mean Squared Error

$$MSE = \frac{1}{2} \cdot \sum_{i=1}^m (y - \hat{y})^2$$